18-04-2023

Analisi del semaforo MUTEX

- Sono utili nella gestione delle risorse condivise per la mutua esclusione.
- Sono validi quando si fa uso di thread implementati nello spazio utente:
 - non vengono riconosciuti dal Kernel e quindi non sono soggetti a scheduling
 - Eventuale scheduling è gestito dallo stesso processo
 - Quando un thread si blocca, blocca l'intero processo visto che il kernel non li conosce

Mutex si può trovare in 2 stati: locked (valore 1) e unlocked (valore 0)

```
Si usa mutex_lock() e mutex_unlock():
```

```
mutex_lock:
    TSL REGISTER,MUTEX -- Mutex viene copiata in REGISTER viene incrementato il valore
    CMP REGISTER,#0
    JZE ok --Accede alla sezione critica se MUTEX = 0
    CALL thread_yield
    JMP mutex_lock
ok:RET

mutex_unlock:
    MOVE MUTEX,#0
    RET
```

Sono molto simili a enter_region/leave_region ma:

- devono essere possibili l'uso delle istruzioni TSL/XCHG visto che si è a livello utente
- Non si ha busy waiting se si usa MUTEX

Differenze fra le 2 versioni:



- Sinistra: Se il CMP fallisce allora avviene l'iterazione infinita fino a quando viene soddisfatta la condizione
- Destra: I thread a livello utente non sono conosciuti dal kernel, allora non sono soggetti a scheduling dal kernel ma è fatto dal processo stesso.
 - Si ha un vantaggio perchè si può usare uno scheduling personalizzato ma il processo non ha il clock che ha il kernel e quindi non si può decidere per quanto tempo eseguire un processo. E' il processo stesso a rilasciare la CPU volontariamente

- Se si trova MUTEX occupato (locked), allora si esegue CALL thread_yield ed è la chiamata di sistema che rilascia la CPU volontariamente e viene eseguito un altro thread dello stesso processo.
- Questa operazione è veloce perchè gestita dallo stesso processo

Quindi mutex_lock e mutex_unlock non fanno chiamate al kernel, quindi si velocizzano le varie operazioni. Esse sono molto utili a LIVELLO UTENTE

Futex

Gli spin-lock, pur consumando la CPU, può essere breve ma se non lo è si ha lo spreco dell'unità di elaborazione

Futex è una caratteristica tipica in Linux:

- un sistema è in grado di gestire numerose contese nelle parti condivise e il kernel si occupa di risvegliarlo
- diventa efficiente quando le contese sono frequenti. Se non lo fossero, le chiamate al kernel (più costose) penalizzano e aumentano il costo
- implementa un sistema lock, simile a MUTEX, senza attivare il kernel e quindi non coninvolgerlo quasi mai
- E' formato da 2 parti:
 - servizio kernel: che fornisce una coda di attesa che consente a più processi di andare in pausa (lock). E' il kernel stesso che li sblocca in maniera esplicita. Attraverso una chiamata di sistema si fanno tali operazioni.
 - libreria utente:

FUTEX agisce interamente nello spazio utente:

- se lock = 1, un thread acquisisce il lock e accede alla sezione critica
- quindi lock viene decrementato così da garantire la mutua esclusione
- Se lock è già occupato da un altro, quindi vale 0, allora la libreria FUTEX, piuttosto che fare busy waiting, allora questo thread viene messo nella coda di attesa che si trova nel kernel tramite chiamata di sistema
- Quando lock = 1 (di nuovo), allora il kernel risveglia il thread che è stato messo in attesa

Se non ci sono contese alla variabile lock, allora non ci sono chiamate al kernel e quindi le esecuzioni sono più veloci

Se ho contese alla variabile lock, allora probabilmente devo fare chiamate di sistema al kernel

Monitor

Soluzione efficiente per gestire la *mutua esclusione*:

- è una raccolta di variabili, procedure ecc che sono raggruppate in un PACCHETTO
- sono dei costrutti in un determinato linguaggio di programmazione

Per esempio, con la **OOP** ci sono parti private (variabili, strutture dati e qualche metodo) e pubbliche (tutto il resto)

Quando si vuole accedere a parti private di un oggetto si ottiene un errore visto che esse possono essere lette solo dai metodi pubblici nello stesso oggetto.

La stessa cosa avviene con i Monitor:

- Il compilatore sa che la struttura dati (l'insieme dei dati) è una parte speciale e quindi va gestita in modo diverso rispetto ad altri metodi/procedure
- Tutti i processi possono chiamare le procedure di un monitor ma non si può accedere alla struttura interna di questo mondo se non attraverso le procedure offerte dal monitor stesso
- Per ottenere una corretta mutua esclusione, in ogni istante può essere attivo un solo processo alla volta all'interno di questo mondo
- · La prima istruzione, infatti, verifica che non ci sia nessun altro processo che sia attivo
- Se nessun processo sta usando il monitor, allora quel processo stesso può usare le procedure del monitor

Mutua esclusione

La mutua esclusione è **gestita dal compilatore** e non dal programmatore visto che viene gestita tramite una **MUTEX** o tramite un **semaforo binario**

Con i monitor è possibile **gestire le race conditions** convertendo le regioni critiche in **procedure di monitor** -> si ha che **MAI due processi si trovano allo stesso tempo in esecuzione all'interno del monitor**.

Nel caso produttore-consumatore come si blocca un processo che non può proseguire? (buffer pieno) Come si gestisce la sincronizzazione?

- si usano variabili condizioni, insieme alle operazioni wait e signal, permettono di gestire la sincronizzazione delle operazioni
- si deve gestire quando un processo può eseguire la sua operazione e quando non è possibile.
 - La mutua esclusione è gestita dai monitor in modo automatico tramite la conversione delle regione critiche in procedure del monitor stesso
- la wait sospende il processo chiamante finchè non viene invocata la sua alternativa, cioè la signal che risveglia il processo addormentato da wait
 - Se viene invocata signal e non ci sono processi bloccati, allora non si avranno effetti

Produttore-consumatore

Si deve gestire che il produttore può eseguire la sua operazione finchè il buffer non è pieno e viceversa per il consumatore.

- Si esegue una wait su una variabile condizione (per esempio la full che si era usata come semaforo). Se è piena allora il processo chiamante viene bloccato e in questo caso si può consentire agli altri di proseguire le proprie operazioni.
- quindi il consumatore può operare che, più avanti, userà signal sulla variabile condizione (full)

Cosa accade dopo signal? per evitare che **2 processi siano attivi allo stesso tempo nel monitor**, allora si deve decidere chi deve continuare la sua operazioni dopo la signal.

- 1. Il metodo Hoare: il processo che deve essere eseguito è quello APPENA SVEGLIATO
- 2. Il metodo Brinch-Hansen: il processo che esegue signal deve uscire subito dal monitor e rappresenta proprio la sua ultima istruzione che appare all'interno di quel processo. Se viene fatto una signal come ultima istruzione di una procedura su cui ci sono in attesa più processi su questa

variabile condizione, verrà selezionata uno di questo "in attesa" come nuovo processo risvegliato

3. L'ultimo metodo: si manda la signal ma in esecuzione continua a rimanere chi ha eseguito la signal. Chi si è appena svegliato continua ad aspettare che il chiamante termini la sua esecuzione

La wait deve arrivare prima di una signal altrimenti verrà persa

Differenze cruciali fra sleep, wakeup

Quando la wakeup andava a vuoto, con i monitor questo non può succedere perchè la mutua esclusione è garantita dalle stesse procedure dei monitor

- wait -> sospende un processo (in caso di regione critica occupata) finchè non viene riattivato
- signal -> risveglia un processo sospeso, quindi in wait(). Se non c'è nessun processo in wait
 allora questa chiamata va a vuoto

Esempio: Dato un processo P che esegue una signal(x) e un processo Q che è in sleep(x). Entrambi i processi possono andare in esecuzione ma chi ci va? Continua P o si esegue Q?

- Hoare: signal & wait -> P viene sospeso (sleep) e Q va in esecuzione
- Mesa: signal & continue -> Q riceve la signal ma aspetta che P termina la sua operazione
- Compromesso: signal & return -> usato con concurrent Pascal cioè: P fa signal, lascia il monitor a
 Q che viene immediatamente ripreso

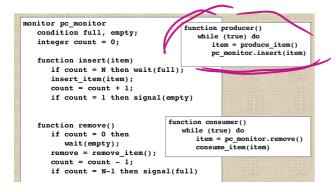
Molti linguaggi di programmazione gestiscono i monitor (C#, Java) mentre altri non hanno i monitor (C) e in questo caso va implementato diversamente.

In Java si usa la parola chiave **SYNCHRONIZED** per identificare un metodo monitor e vuol dire che nessun altro thread può eseguire un altro metodo synchronized dello stesso oggetto

Svantaggi dei monitor

Non sono gestiti da tutti i linguaggi di programmazione e quindi non sono gestiti dal compilatore

Esempio produttore-consumatore con i monitor



- count gestisce la variabile condizione e indica il numero di elementi nel buffer
- Si usano 4 metodi di una classe pc monitor
- Viene usato il modello Hoare, cioè signal & wait
- Si usano le variabili condizione full e empty -> full serve per sospendere il produttore per sospendere il consumatore

In questo esempio si è applicato il metodo Brinch-Hansen